



3. Data Preparation

בחירת נתונים

הרשומות והמאפיינים הרלוונטיים שלנו הם:
- נתוני מחירי המניות: AAPL,GOOGL,NVDA
- נתוני המאקרו: fed rate, inflation cpi, consumer confidence, sp500, VIX,US10Y
- משתנה המטרה: Stock return

הסיבה להשאת הנתונים

בשלב זה בחרנו להשאיר את המאפיינים כי ראינו בהם השפעה על התשואות היומיות. נתוני המאקרו משקפים את מצב הכלכלה ומשפיעים באופן ישיר על שוק ההון.

ביצוע ניקוי נתונים

-נבדקו ערכי NULL בטבלאות שייבאו לSQL באמצעות שאילתות LEFT JOIN, ובוצעו בדיקות COUNT. נמצא כי אין עמודות NULL, ואין תאריכים חסרים.
-בעת ייבוא CSV חלק מהעמודות הוגדרו כ VARCHAR.
-בוצעו בדיקות כפילויות.
-בוצעו אחידות של תאריכים, נבנה טבלת Dim_Date המאחדת את התאריכים מהטבלאות באמצעות UNION. לצורך יצירת מבנה נתונים והגדרת קשרי Foreign Key.

טיפול בנתונים

-נבדקו outliers בתשואות במסגרת EDA וראינו כי ישנם כמה תצפיות חריגות אך לא הוסרו, זאת מאחר והם מייצגים אירועי שוק אמיתיים ולא כשגיאות נתונים.
-נתוני המאקרו יושרו לתדירות יומית באמצעות פונקציית תדירות ASFREQ המבצעת רצף של תאריכים גם במידה ואין יום/ערך, ובאמצעות forward fill ממלאת לפי יום קודם. כל הנתונים נשמרו בטבלה fact_macro_daily והחיבור לנתוני המניות נעשה על בסיס השדה date.
בכך הומרו נתוני המאקרו לתדירות יומית התואמת לנתוני המניות, כך שכל יום מסחר קיבל ערך מאקרו רלוונטי.

Feature Engineering

-בחרנו ב-Stock Return כמשתנה מטרה משום שהוא מתאר את השינוי היחסי במחיר המניה מיום ליום, ולא את המחיר עצמו, כך ניתן להשוות בין מניות שונות גם אם רמות המחיר שלהן שונות. בנוסף, תשואות יומיות מאפשרות לזהות תגובות מהירות לאירועי שוק ולשלב בצורה טבעית נתוני מאקרו הנמדדים על בסיס יומי.
-החישוב של Stock return בוצע על בסיס מחירי הסגירה היומיים המתואמים שנשלפו ממקור הנתונים תוך השוואה למחיר יום המסחר הקודם עבור כל מניה.



-לא נוצרו משתני Lag במסד נתונים, רק ביצענו הזזה של יום אחד לאחור על מנת שנוכל לחשב חישוב התשואה.

- בשלב זה לא נוצרו מאפיינים מסוג Moving Averages או Rolling Features. מאפיינים אלו מחושבים על פני חלון זמן מתגלגל (מספר ימים אחורה לכל תאריך), ואינם תלויים בטווח התאריכים הכולל של מסד הנתונים.

נרמול/סטנדרטיזציה

לא בוצע נרמול למשתנה המטרה כי הוא מחושב כיחס ולכן כבר מנורמל באופן כפי שלקחנו מהמקורות.

אינטגרציה של נתונים

בוצעה אינטגרציה בין fact_prices_daily ו fact_macro_daily באמצעות JOIN על השדה DATE.

עיצוב ופורמט נתונים

הנתונים הוכנסו למסד הנתונים לפי השדות הבאים:

Dimensions:

dim_date (PK: date) -

dim_stock (PK: symbol) -

Fact Tables:

fact_prices_daily (PK: symbol, date) -

fact_macro_daily (PK: date) -

Foreign Keys:


fact_prices_daily -> dim_date -

fact_prices_daily -> dim_stock -

fact_macro_daily -> dim_date -



צירוף צילום של ה-ERD הסופי:





ניתוח חוקר EDA

סטטיסטיקה תיאורית- משתנה מטרה STOCK RETURN :

0.24 0.0015 -0.19 0.02

Max Stock retur...

Avg Stock return

Min Stock return


Std Stock return

בוצעו : ממוצע תשואה יומית, סטיית תקן, מינימום יומי, מקסימום יומי.

סטטיסטיקה תיאורית למאפיינים חשובים- נתוני מאקרו :

קשר בין תשואה יומית - VIX


symbol ● AAPL ● GOOGL ● NVDA



ראינו כי מדד הVIX בעל הקשר החזק ביותר- קשר שלילי מתון למדד התשואה היומית.

היסטוגרמה להצגת התפלגות תשואות:

התפלגות תשואות



ריכוז התשואות סביב ה0 אשר מצביע כי רוב ימי הסחר מאופיינים בשינויים יחסית קטנים, לא נראה הטיה מובהקת לכיוון חיובי או שלילי.



Corr Return Fed Rate	Corr Return SP500	Corr Return US10Y	Corr Return VIX	symbol
-0.02	0.01	-0.03	-0.13	☒ AAPL
				☐ GOOGL
				☐ NVDA

ביצענו קורלציה ו מהניתוח עולה כי הקשר בין התשואה היומית למשתני המאקרו שנבדקו חלש באופן כללי. מדד ה־VIX בולט כמשתנה היחסי המשמעותי ביותר, בעוד ששאר המשתנים מראים קשר זניח לתשואה היומית.

Corr Return Fed Rate	Corr Return SP500	Corr Return US10Y	Corr Return VIX	symbol
0.01	0.04	0.00	-0.12	☐ AAPL
				☒ GOOGL
				☐ NVDA

גם במקרה של GOOGL ניתן לראות כי מדד ה־VIX הוא המשתנה היחיד שמראה קשר כלשהו לתשואה היומית, בעוד שהשפעת יתר המשתנים כמעט ואינה ניכרת.

Corr Return Fed Rate	Corr Return SP500	Corr Return US10Y	Corr Return VIX	symbol
0.02	0.02	0.00	-0.10	☐ AAPL
				☐ GOOGL
				☒ NVDA

גם עבור מניית NVDA מתקבל דפוס דומה, שבו מדד ה־VIX מציג את הקורלציה הגבוהה ביותר לתשואה היומית, בעוד שיתר משתני המאקרו מציגים קשר חלש מאוד או זניח. ניתוח הקורלציה עבור AAPL, GOOGL ו-NVDA מראה דפוס עקבי שבו מדד ה־VIX הוא המשתנה המאקרו בעל הקשר החזק ביותר לתשואה היומית, אם כי ברמה חלשה. לעומת זאת, משתני ריבית, אג"ח ומדד S&P500 מציגים קשר זניח, דבר המחזק את המסקנה כי ברמה היומית השפעתם מוגבלת.

את שני המדדים Inflation CPI ו-Consumer Confidence לא הכנסו לניתוח הקורלציה כי מדובר במדדים חודשיים המשתנים בקצב איטי, ולכן אינם מתאימים לניתוח קשרים ברמה של תשואה יומית, שבה נדרשת תגובה מהירה לאירועי שוק.



דו"ח התקדמות להגשה לשלב Data Preparation

שמות הסטודנטים ניקול בלישר נועם פטיש

מס' ת"ז 212205082 328654546

שם הפרויקט: חיזוי מניות

שם המנחה ג'ניס גוטפריד

לקחנו את הנתונים והעברנו למסד נתונים של SQL SERVER, ואז לאחר מכן עשינו בדיקות באמצעות שאילתות במידה ויש NULL וכפילויות. ואז חיברנו את הטבלאות באמצעות מפתחות והגדרנו קשרים. ראינו לנכון להשאיר את הנתונים כיוון שהם משקפים ומשפיעים על השוק וזה מה שאנו מנסות לחזות באמצעות המודל. עשינו ניתוח EDA המשקף את הניתוחים הסטטיסטיים את המדדים, ותרשימים אשר פירטנו והסברנו כיצד המדדים משפיעים ואילו הכי הרבה על השוק.

חתימת המנחה

תאריך 25/02/2026