



## השוואת מודלים על בסיס קריטריונים בחרנו את DAILY RETURN LOW-HIGH :

במהלך שלב ההערכה זוהה כי המשתנים `daily_return_high` ו-`daily_return_low` עשויים ליצור מצב של Data Leakage, מאחר שהם מבוססים על נתוני מסחר מאותו יום של התחזית. החשד לכך עלה לאחר ניתוח Feature Importance, שבו שני משתנים אלו קיבלו את ערכי החשיבות הגבוהים ביותר במודל בהשוואה לשאר המשתנים. דבר שהראה כי המודל נשען עליהם בצורה משמעותית לצורך ביצוע החיזוי.

```
# 5. המשתנים שהכי השפיעו
importances = pd.Series(model_rf.feature_importances_, index=X_train.columns).sort_values(ascending=False)
print("\n המשתנים שהכי השפיעו על החיזוי:")
print(importances.head(5))
```

המשתנים שהכי השפיעו על החיזוי:

|                                |          |
|--------------------------------|----------|
| <code>daily_return_high</code> | 0.340273 |
| <code>daily_return_low</code>  | 0.316228 |
| <code>VIX</code>               | 0.057080 |
| <code>volume</code>            | 0.053226 |
| <code>SP500</code>             | 0.046468 |

על מנת לבדוק האם המודלים אכן מסתמכים על מידע שאינו זמין בזמן אמת למשקיע, בוצע ניסוי נוסף שבו המשתנים `daily_return_high` ו-`daily_return_low` הוסרו ממערך הנתונים.

```
X = df.drop(columns=[
    'stock_return',
    'date',
    'symbol',
    'daily_return_high',
    'daily_return_low'
], errors='ignore')
```

לאחר הסרתם נצפתה ירידה משמעותית בביצועי המודלים :


- Random Forest ירד מ-86% Accuracy ל-52%

- XGBoost ירד מ-85% Accuracy ל-55%

ממצא זה מחזק את ההשערה כי המודלים הסתמכו במידה רבה על מידע הקשור ישירות לתוצאת יום המסחר עצמו, ולכן תוצאות הניסוי השני נחשבות לאמינות וריאליסטיות יותר לצורך חיזוי אמיתי של שוק ההון.



## דירוג מודים לפי מדדים כמותיים:



בוצע חישוב ROC-AUC לצורך הערכה נוספת של יכולת הסיווג של המודל. תוצאת ה-AUC שהתקבלה הייתה 0.49, ערך הקרוב ל-0.5, דבר המעיד כי יכולת ההבחנה של המודל בין עלייה לירידה במניה נמוכה יחסית ודומה לביצוע אקראי.

גם גרף ה-ROC הציג עקומה הקרובה לאלכסון, דבר המחזק את המסקנה כי חיזוי תנועות יומיות בשוק ההון הוא משימה מורכבת במיוחד לאחר הסרת משתנים שיצרו Data Leakage.

עם זאת, תוצאות אלו נחשבות לאמינות יותר, מאחר שהמודל נבחן על נתונים שלא נראו במהלך האימון וללא שימוש במידע שעלול לדלוף מתוצאת יום המסחר עצמו.



## השוואת המודלים ובחירת מדדי הערכה:

| Model           | Accuracy | Precision | Recall | F1   |
|-----------------|----------|-----------|--------|------|
| RF מקור         | 0.86     | 0.90      | 0.84   | 0.87 |
| XGB מקור        | 0.85     | 0.90      | 0.83   | 0.86 |
| RF ללא leakage  | 0.52     | 0.58      | 0.53   | 0.56 |
| XGB ללא leakage | 0.55     | 0.59      | 0.66   | 0.62 |


מהטבלה ניתן לראות כי לאחר הסרת משתני ה־Data Leakage חלה ירידה משמעותית בביצועי שני המודלים. עם זאת, תוצאות אלו משקפות בצורה אמינה יותר את יכולת החיזוי האמיתית של המודלים, מאחר שהן אינן מסתמכות על מידע שאינו זמין בזמן אמת.

בפריקט זה בחרנו להתמקד במדדי Precision ו־F1-score. הסיבה לכך היא שבחיזוי שוק ההון חשוב לא רק לדעת כמה תחזיות היו נכונות באופן כללי, אלא גם עד כמה ניתן לסמוך על תחזיות העלייה שהמודל מספק למשקיע.

מדד Precision בוחן את אחוז תחזיות העלייה שהיו נכונות בפועל, ולכן הוא חשוב במיוחד לצמצום מצבים שבהם המודל ממליץ על השקעה שבסופו של דבר אינה משתלמת. בנוסף, מדד F1-score משלב בין Precision לבין Recall ומספק הערכה מאוזנת יותר של ביצועי המודל. מסיבה זו התבססנו בעיקר על מדדים אלו בעת הערכת המודלים ובחירת המודל הסופי.



## :CONFUSION MATRIX



בנוסף למדדי הביצועים, נבנתה גם Confusion Matrix לצורך ניתוח מפורט יותר של תחזיות המודל. מהמטריצה ניתן לראות כי המודל הצליח לזהות בצורה טובה יותר מצבים של עלייה במניה (Up) בהשוואה למצבים של ירידה (Down).

המודל חזה נכון 271 מקרים של עלייה במניה ו-188 מקרים של ירידה. עם זאת, ניתן לראות כי קיימים גם מספר לא קטן של סיווגים שגויים, דבר המעיד על הקושי בזיהוי מדויק של תנועות יומיות בשוק ההון. ממצאים אלו תואמים למדדי ה-Accuracy וה-AUC שהתקבלו, ומחזקים את המסקנה כי לאחר הסרת משתנים שיצרו Data Leakage, ביצועי המודל הפכו לריאליסטיים יותר אך גם מאתגרים יותר מבחינת יכולת החיזוי.



## Fine Tuning וכוונן פרמטרים:

```
n_estimators=200  
max_depth=10  
min_samples_split=5
```

בשלב Fine Tuning בוצעו מספר ניסויים למודל Random Forest באמצעות שינוי פרמטרים מרכזיים, כגון מספר העצים במודל (n\_estimators) ועומק העצים (max\_depth). בתחילה בוצע כוונן בסיסי באמצעות קוד ידני פשוט, שבו נוסו מספר ערכים בודדים לפרמטרים המרכזיים. בניסוי זה התקבל שיפור קטן בלבד, כאשר ביצועי המודל השתפרו מ-52% ל-53% Accuracy.

## Fine Tuning מורחב:

```
models_to_test = {  
    "RF_Default": RandomForestClassifier(n_estimators=100, random_state=42),  
  
    "RF_200_depth10": RandomForestClassifier(  
        n_estimators=200,  
        max_depth=10,  
        random_state=42  
    ),  
  
    "RF_300_depth15": RandomForestClassifier(  
        n_estimators=300,  
        max_depth=15,  
        random_state=42  
    )  
}  
  
for name, model in models_to_test.items():  
  
    model.fit(X_train, y_train_class)  
  
    y_pred = model.predict(X_val)  
  
    print("\n", name)  
  
    print(f"Accuracy: {accuracy_score(y_val_class, y_pred):.2f}")  
  
    print(classification_report(y_val_class, y_pred))
```

לאחר מכן הוחלט לבצע תהליך Fine Tuning רחב ומסודר יותר, שבו הורחב הקוד ונבדקו מספר שילובים שונים של פרמטרים עבור מודל Random Forest. מטרת התהליך הייתה לבדוק כיצד שינוי הפרמטרים משפיע על יכולת החיזוי של המודל.

במסגרת הניסויים נמצא כי המודל בעל n\_estimators=300 ו-max\_depth=15 השיג את התוצאה הטובה ביותר עם Accuracy של 55%, זה תוצאה טובה יותר מ-53%.

למרות השיפור שהתקבל לאחר כוונן הפרמטרים, מדובר בשיפור מתון יחסית, דבר שממחיש את המורכבות של חיזוי מגמות יומיות בשוק ההון לאחר הסרת משתנים שעלולים לגרום ל-Data Leakage.



## ביצוע הרצה על נתונים חדשים - TEST:

```
y_test_class = (y_test > 0).astype(int)

final_model = RandomForestClassifier(
    n_estimators=300,
    max_depth=15,
    random_state=42
)

final_model.fit(X_train, y_train_class)

y_pred_test = final_model.predict(X_test)
print()
print("Final Test Results-RANDOM FOREST")

print(f"Accuracy: {accuracy_score(y_test_class, y_pred_test):.2f}")

print(classification_report(y_test_class, y_pred_test))
```

## תוצאות הרצה ראשונית על ה-TEST:

```
Final Test Results-RANDOM FOREST
Accuracy: 0.50
```

|              | precision | recall | f1-score | support |
|--------------|-----------|--------|----------|---------|
| 0            | 0.45      | 0.43   | 0.44     | 411     |
| 1            | 0.53      | 0.55   | 0.54     | 480     |
| accuracy     |           |        | 0.50     | 891     |
| macro avg    | 0.49      | 0.49   | 0.49     | 891     |
| weighted avg | 0.50      | 0.50   | 0.50     | 891     |

לאחר בחירת המודל הסופי וביצוע תהליך Fine Tuning, בוצעה הרצה סופית על קבוצת ה-Test, אשר הופרדה מראש ממערך הנתונים ולא שימשה במהלך האימון או תהליך הכוונון. החלוקה בוצעה כך ש־70% מהנתונים שימשו לאימון המודל, 15% ל-Validation לצורך השוואת מודלים וכוונון פרמטרים, ו־15% נוספים נשמרו כקבוצת Test לבדיקה הסופית בלבד.

מטרת שלב זה הייתה לבדוק את יכולת ההכללה של המודל על נתונים שלא נראו במהלך תהליך הלמידה. תוצאות ההרצה הסופית הראו כי מודל Random Forest השיג Accuracy של 50% על קבוצת ה-Test, לצד ערכי Precision ו-F1-score מאוזנים יחסית בין מחלקות העלייה והירידה.



## ביצוע השוואה עם ה-Validation:

```
y_train_class = (y_train > 0).astype(int)
y_val_class = (y_val > 0).astype(int)

# 1. הגדרת המודל
model_rf = RandomForestClassifier(n_estimators=100, random_state=42)

# 2. אימון המודל (שימי לב שאנחנו משתמשים ב-y_train_class החדש)
model_rf.fit(X_train, y_train_class)

# 3. ביצוע תחזית על נתוני ה-Validation
y_pred_val = model_rf.predict(X_val)

# 4. הדפסת התוצאות (משווים מול y_val_class)
print("תוצאות הרצה ראשונית (Validation Set)")
print(f"Accuracy (דיוק כללי): {accuracy_score(y_val_class, y_pred_val):.2f}")

print("\nClassification Report - Random Forest:")
print(classification_report(y_val_class, y_pred_val))
```

## תוצאות הרצה ראשונית על ה-Validation:

| תוצאות הרצה ראשונית (Validation Set)   |           |        |          |         |
|----------------------------------------|-----------|--------|----------|---------|
| Accuracy (דיוק כללי): 0.52             |           |        |          |         |
| Classification Report - Random Forest: |           |        |          |         |
|                                        | precision | recall | f1-score | support |
| 0                                      | 0.44      | 0.49   | 0.47     | 383     |
| 1                                      | 0.58      | 0.53   | 0.56     | 508     |
| accuracy                               |           |        | 0.52     | 891     |
| macro avg                              | 0.51      | 0.51   | 0.51     | 891     |
| weighted avg                           | 0.52      | 0.52   | 0.52     | 891     |

בהשוואה לתוצאות שהתקבלו על קבוצת ה-Validation, נצפתה ירידה מסוימת בביצועי המודל. ממצא זה מצביע על כך שחיזוי תנועות יומיות בשוק ההון הוא משימה מורכבת מאוד, במיוחד לאחר הסרת משתנים שעלולים לגרום ל-Data Leakage. למרות הירידה בביצועים, תוצאות אלו נחשבות לאמינות יותר מאחר שהמודל נבחן על נתונים חדשים לחלוטין מבחינת תהליך הלמידה.



## דו"ח התקדמות להגשה לשלב Evaluation

שמות הסטודנטים ניקול בלישר נועם פטיש

מס' ת"ז 212205082 328654546

שם הפרויקט חיזוי מניות

שם המנחה ג'ניה גוטפריד

בשלב זה ביצענו תהליך Evaluation למודלי החיזוי בפרויקט באמצעות חלוקת הנתונים ל- Train, Test ו- Validation. הורצו מודלי Random Forest ו- XGBoost ונמדדו ביצועיהם באמצעות Accuracy, Precision, F1-score ו- ROC-AUC. במהלך העבודה זוהתה בעיית Data Leakage במשתנים daily\_return\_high ו- daily\_return\_low, ולכן בוצע ניסוי נוסף ללא משתנים אלו לקבלת תוצאות אמינות יותר. בנוסף בוצע Fine Tuning למודל Random Forest ונבחר המודל בעל הביצועים הטובים ביותר. לבסוף בוצעה הרצה סופית על קבוצת Test והמודל נשמר בקובץ PKL לצורך שימוש עתידי בשלב ה- Deployment.

חתימת הסטודנט ניקול בלישר

חתימת הסטודנט נועם פטיש

חתימת המנחה

תאריך 09/06/2026